

Reconhecimento de padrões


- Reconhecimento de padrões e classificação
- Atributos
- O problema indutivo
- Aprendizagem supervisionada e não supervisionada
- Classificação paramétrica e não paramétrica
 - Classificação paramétrica com base em regras de decisão
- Classificação nítida e classificação nebulosa (*fuzzy*)

Reconhecimento de Padrões e Classificação:


- Capacidade humana inata.
- Tarefas corriqueiras:
 - reconhecer pessoas,
 - reconhecer objetos,
 - etc.
- São exemplos de padrões:
 - sons, vozes, música,
 - aromas, perfumes,
 - etc.

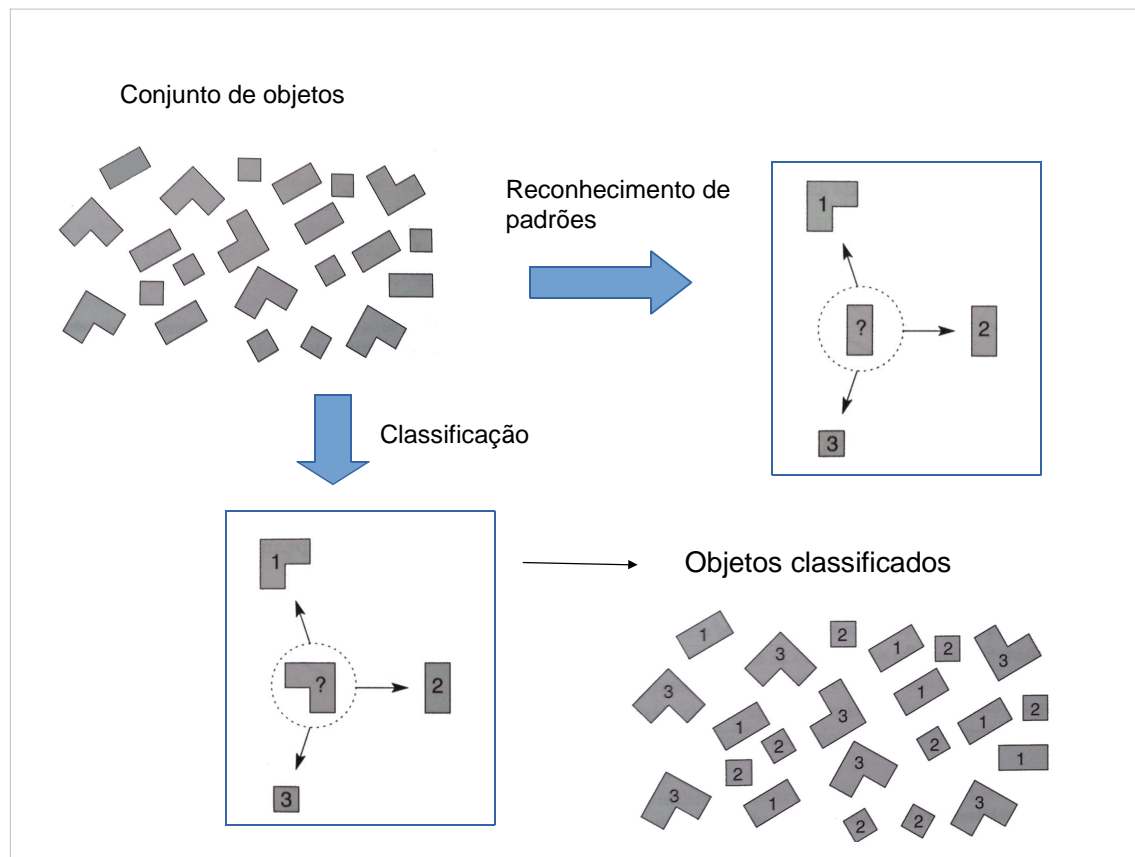


Criar classes após análise dos objetos:



Separar objetos em classes já conhecidas:





Supports Open Access

Pattern Recognition


The Journal of the Pattern Recognition Society

Pattern Recognition is the official journal of the Pattern Recognition Society. The Society was formed to fill a need for information exchange among research workers in the **pattern recognition** field. Up to now, we "pattern-recognitionophiles" have been tagging along in computer science, information theory, optical processing techniques, and other miscellaneous fields. Because this work in pattern recognition presently appears in widely spread articles and as isolated lectures in conferences in many diverse areas, the purpose of the journal *Pattern Recognition* is to give all of us an opportunity to get together in one place to publish our work. The journal will thereby expedite communication among research scientists interested in pattern recognition.

We consider pattern recognition in the broad sense, and we assume that the journal will be read by people with a common interest in pattern recognition but from many diverse backgrounds. These include biometrics, target recognition, biological taxonomy, meteorology, space science, classification methods, character recognition, image processing, industrial applications, neural computing, and many others.



The publication policy is to publish (1) new original articles that have been appropriately reviewed by competent scientific people, (2) reviews of developments in the field, and (3) pedagogical papers covering specific areas of interest in pattern recognition. Various special issues will be organized from time to time on current topics of interest to Pattern Recognition.

- We consider **pattern recognition** in the broad sense, and we assume that the journal will be read by people with a common interest in pattern recognition but from many diverse backgrounds. These include **biometrics, target recognition, biological taxonomy, meteorology, space science, classification methods, character recognition, image processing, industrial applications, neural computing, and many others.**




The International Association for Pattern Recognition (IAPR) is an international association of non-profit, scientific or professional organizations (being national, multi-national, or international in scope) **concerned with pattern recognition, computer vision, and image processing in a broad sense**. Normally, only one organization is admitted from any one country, and individuals interested in taking part in IAPR's activities may do so by joining their national organization.

Reconhecimento de padrões e campos relacionados:



- A característica ou atributo é qualquer aspecto, qualitativo ou quantitativo.
A característica pode ser simbólica (ex. cor) ou numérica (ex. altura)

Exemplo: Silhueta de objetos a partir da imagem captada por uma câmara.
Podem ser extraídos para os objetos as características ou atributos e seus possíveis valores:



Atributo	Possíveis valores
tamanho	Pequeno, grande
forma	Longa, compacta, outra
furos	0, 1, 2, 3, muitos

Aprendizado

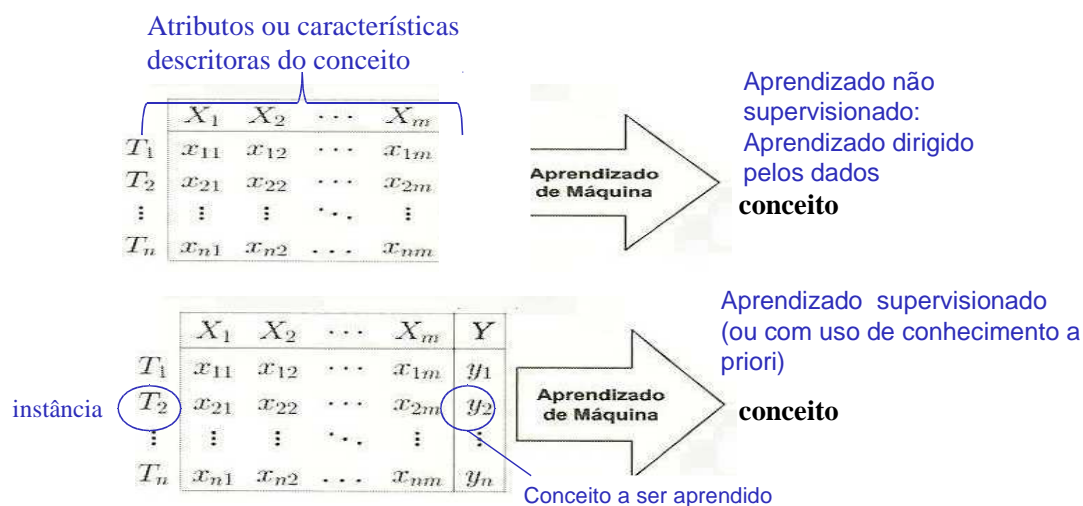
- Modificação na estrutura do conhecimento do sistema que permite que ele tenha melhor desempenho em repetições do mesmo tipo de tarefa.
(Enfoque da inteligência artificial)
- **“any change in a system that allows it to perform better the second time on repetition of the same task or on another task drawn from the same population” (Simon, 1983)**

Aprendizado de máquina (Machine Learning)

é uma área da Inteligência Artificial cujo objetivo principal é o desenvolvimento de técnicas computacionais relacionadas ao aprendizado bem como a construção de sistemas capazes de adquirir conhecimento de forma automática.

Aprender como?

- Dados alguns **exemplos** de um determinado conceito, tentar **inferir** uma definição que permita ao aprendiz reconhecer futuras instâncias daquele conceito.



- Uma vez aprendido o conceito, o sistema deve reconhecer/classificar instâncias ainda não observadas.


Atributos				Atributos			
Tamanho	Forma	Furos		Tamanho	Forma	Furos	Objeto
grande	longa	0		grande	longa	0	lápis
grande	longa	0		grande	longa	0	lápis
pequeno	longa	0		pequeno	longa	0	parafuso
pequeno	compacta	0		pequeno	compacta	0	parafuso
grande	longa	1		grande	longa	1	chave
pequeno	compacta	1		pequeno	compacta	1	porca
pequeno	longa	1		pequeno	longa	1	chave
pequeno	compacta	1		pequeno	compacta	1	porca
pequeno	compacta	1		pequeno	compacta	1	porca
Instância → grande	longa	2		grande	longa	2	tesoura
grande	outra	2		grande	outra	2	tesoura
pequeno	outra	2		pequeno	outra	2	chave

Conceito

-Aprendizagem de conceito: a partir de exemplos de um determinado conceito, inferir uma definição que permitirá reconhecer corretamente *futuras ocorrências daquele conceito*.

- **Problema da indução:** a partir da experiência (limitada) a partir de alguns exemplos do domínio do problema, o aprendiz deve ser capaz de generalizar corretamente para instâncias não vistas anteriormente.

-> Capacidade de Generalização



Os critérios de aprendizado constituem “vieses indutivos”

- *Por ex., Métodos Paramétricos:* assumem que cada classe têm distribuição normal.

Objetivo da aprendizagem supervisionada;
conjuntos de treinamento e de teste


- o objetivo da aprendizagem é o de que o classificador tenha o menor erro possível em novos dados que provenham duma distribuição idêntica àquela que gerou estes dados.
- Não é possível conhecer o verdadeiro erro de generalização: o que se faz é tentar estimá-lo.
 - Para estimar o erro de generalização divide-se o conjunto de dados em 2 subconjuntos disjuntos: o conjunto de treinamento e o de teste.
 - O conjunto de treinamento é usado para treinar o classificador; o de teste para estimar o seu erro de generalização.

Alguns métodos utilizados na partição do conjunto de dados:

Holdout – Este método divide aleatoriamente os registros em uma percentagem fixa p para **treinamento** e $(1 - p)$ para **teste**.

Embora não existam fundamentos teóricos sobre esta percentagem, valores tipicamente utilizados são:

- $p = 2/3$, e
- $(1 - p) = 1/3$ (Rezende, 2003)



Para n instâncias, dos quais c foram corretamente classificadas, a acurácia preditiva (p) do classificador é:


$$p = c / n$$

Alguns métodos utilizados na partição do conjunto de dados:

Validação Cruzada com K Conjuntos (*K-Fold CrossValidation*) :

Este método consiste em dividir aleatoriamente o conjunto de dados com N elementos em K subconjuntos disjuntos (folds), com aproximadamente o mesmo número de elementos (N / K).

Neste processo, cada um dos K subconjuntos é utilizado como conjunto de teste e os $(K - 1)$ demais subconjuntos são reunidos em um conjunto de treinamento. Assim, o processo é repetido K vezes, sendo gerados e avaliados K modelos de conhecimento.



Alguns métodos utilizados na partição do conjunto de dados:

Validação Cruzada Estratificada com K Conjuntos (*Stratified K-Fold CrossValidation*) :

Este método é similar à Validação Cruzada com K Conjuntos, sendo que ao gerar os subconjuntos mutuamente exclusivos, a proporção de exemplos em cada uma das classes é considerada durante a amostragem.

- Isto significa, por exemplo, que se o conjunto de dados original possui duas classes com distribuição de 20% e 80%, cada subconjunto também deverá conter aproximadamente esta mesma proporção de exemplos distribuídos pelas classes.

Matriz de confusão ou matriz de erros:

Proporciona a informação do número de instâncias da classe X corretamente classificadas como classe X ou incorretamente classificadas como sendo de outra classe.

		Referência			Total
		A	B	C	
Resultado da classificação	A	35	2	2	39
	B	10	37	3	50
	C	5	1	41	47
Total		50	40	46	136

-Elementos na diagonal principal: classificações corretas

-Elementos fora da diagonal: erros de classificação

Exatidão total: Número de pixels corretamente classificados dividido pelo número de pixels de referência.


$$ET = (35+37+41)/136 = 0,8308 \Rightarrow 83,08\%$$

A matriz de erros permite avaliar:

- acurácia do produtor
- acurácia do usuário
- coeficiente de concordância

EXEMPLO



Classificação a partir de descritores de objetos.




Tamanho	Forma	Furos	Objeto
grande	longa	0	lâpis
grande	longa	0	lâpis
pequeno	longa	0	parafuso
pequeno	compacta	0	parafuso
grande	longa	1	chave
pequeno	compacta	1	porca
pequeno	longa	1	chave
pequeno	compacta	1	porca
pequeno	compacta	1	porca
grande	longa	2	tesoura
grande	outra	2	tesoura
pequeno	outra	2	chave

Vetor de características e espaço de características

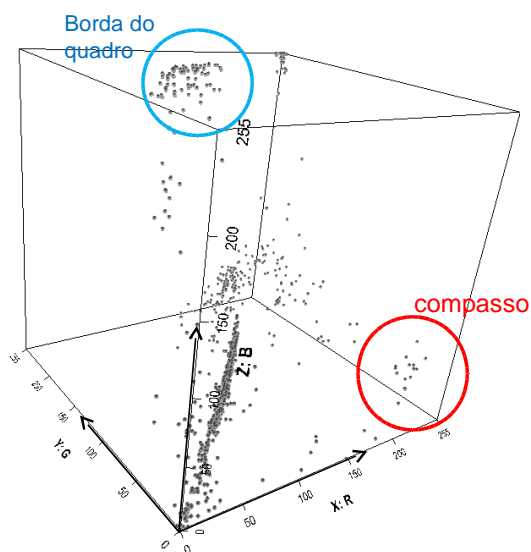
- Os atributos numéricos podem ser representados por meio de um vetor de dimensão p chamado de vetor de características (feature vector),
- O espaço de p -dimensões formado pelo vetor de característica é chamado de espaço de características – feature space
- As instâncias são representados como pontos no espaço de características.



Classificação não supervisionada (Segmentação)



Métodos não supervisionados analisam valores de NDs (pixels) e consideram que pixels que obedecem a um critério de similaridade podem ser agrupados.




Segmentação orientada a regiões

Seja I a imagem de entrada:



A **segmentação** particiona I em n regiões conexas R_1, R_2, \dots, R_n ,

tal que:



- a segmentação deve ser completa, isto é, cada pixel deve pertencer a uma região.	$\bigcup_{i=1}^n R_i = I$
- as regiões devem ser disjuntas.	$R_i \cap R_j = \emptyset \quad \forall i = 1, 2, \dots, n$
- Pixels de uma região devem satisfazer uma propriedade comum.	$P(R_i) = \text{VERDADEIRO}$ para $i = 1, 2, \dots, n$
- Regiões adjacentes R_i e R_j não podem ser unidas numa única região.	$P(R_i \cup R_j) = \text{FALSO}$ para $i \neq j$

Uma região consiste de um grupo de pixels conectados e com propriedades similares.

- > vizinhança
- > similaridade
- > conectividade

Para se estabelecer se dois pixels estão **conectados** é necessário determinar se eles são adjacentes e se seus níveis de cinza satisfazem a um determinado critério de similaridade.

$$\begin{vmatrix} 1 & 1 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{vmatrix}$$

Vizinhança de um pixel (i,j) :

-Vizinhança 4:

$I(i-1,j-1)$	$I(i-1,j)$	$I(i-1,j+1)$
$I(i,j-1)$	$I(i,j)$	$I(i,j+1)$
$I(i+1,j-1)$	$I(i+1,j)$	$I(i+1,j+1)$

-Vizinhança 8:

$I(i-1,j-1)$	$I(i-1,j)$	$I(i-1,j+1)$
$I(i,j-1)$	$I(i,j)$	$I(i,j+1)$
$I(i+1,j-1)$	$I(i+1,j)$	$I(i+1,j+1)$

- Distância entre níveis digitais como medida de similaridade:

$$D = \text{abs}(ND1 - ND2)$$

- Distância euclidiana como medida de similaridade:

$$D = \sqrt{(ND1 - ND2)^2}$$

Exemplo.

Distância euclidiana entre o ND cujo valor é 2 e o ND cujo valor é 5:

$$D = \text{sqrt}((2 - 5)^2)$$

Exemplo de métodos de segmentação:

-Crescimento de regiões:

- > inicia com pixels “semente” representativos de cada região
- > utiliza um critério similaridade
- > é iterativo
 - cada pixel deve ser alocado a uma região

-K médias (*k means*)

- > inicia com valores dos “centróides” de cada região
- > utiliza um critério de similaridade
- > é iterativo
 - os centróides são atualizados em cada iteração

Crescimento de Regiões

É um método iterativo de segmentação da imagem em regiões.

Concepção do método:

Iniciando com pontos semente, as regiões são formadas pelo agrupamento de pixels vizinhos que possuem propriedades similares.

O **critério de similaridade** pode ser definido como um limiar de intensidade, textura, cor, etc.

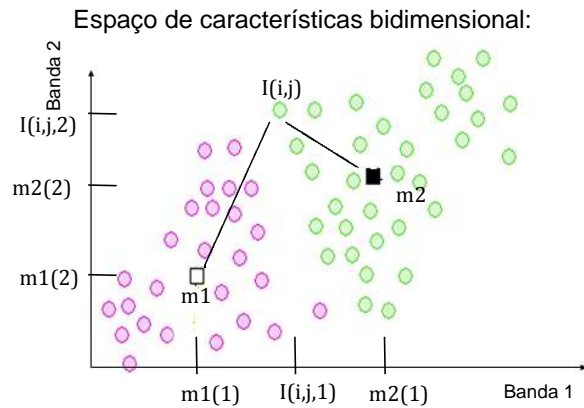



Algoritmo:

1. Escolher os pontos (DNs) semente.
2. Se os pixels vizinhos satisfizerem o critério de similaridade, então as regiões crescerão.
3. Repetir o passo 2 até que todos os pixels da imagem sejam incluídos numa das regiões.

- Algoritmo K-Means

Imagem com duas bandas e representação dos pixels no espaço de características :



Definindo uma **medida de distância**, por ex. Distância euclidiana:


$$d_m1 = \sqrt{(I(i,j,1)-m1(1))^2 + (I(i,j,2)-m1(2))^2};$$

$$d_m2 = \sqrt{(I(i,j,1)-m2(1))^2 + (I(i,j,2)-m2(2))^2};$$


$$\text{minimo} = \min(\text{find}(d_m == \min(d_m)));$$

- Algoritmo K-Means


1. Determinar o número de **clusters** k e selecionar os respectivos centróides.



2. Atribuir a cada pixel o centróide mais próximo, considerando um critério de similaridade.




3. Recalcular os centróides a partir dos pixels que formam cada cluster.




Fim da primeira iteração

4. Repetir os passos 2 e 3 até que um **critério de convergência** seja atingido.



Iteração n

imagem segmentada




Métodos de classificação:

Métodos não supervisionados:

Problema:

Segmentar a imagem (Identificar as classes espectrais)

Métodos supervisionados consideram que as de classes de informação são conhecida a priori, e que são conhecidas amostras (instâncias) de cada classe.



Problema:

Determinar as superfícies de decisão

Métodos de classificação:

Métodos Paramétricos assumem que os pixels de cada classe têm distribuição normal e que as funções densidade das classes são conhecidas.

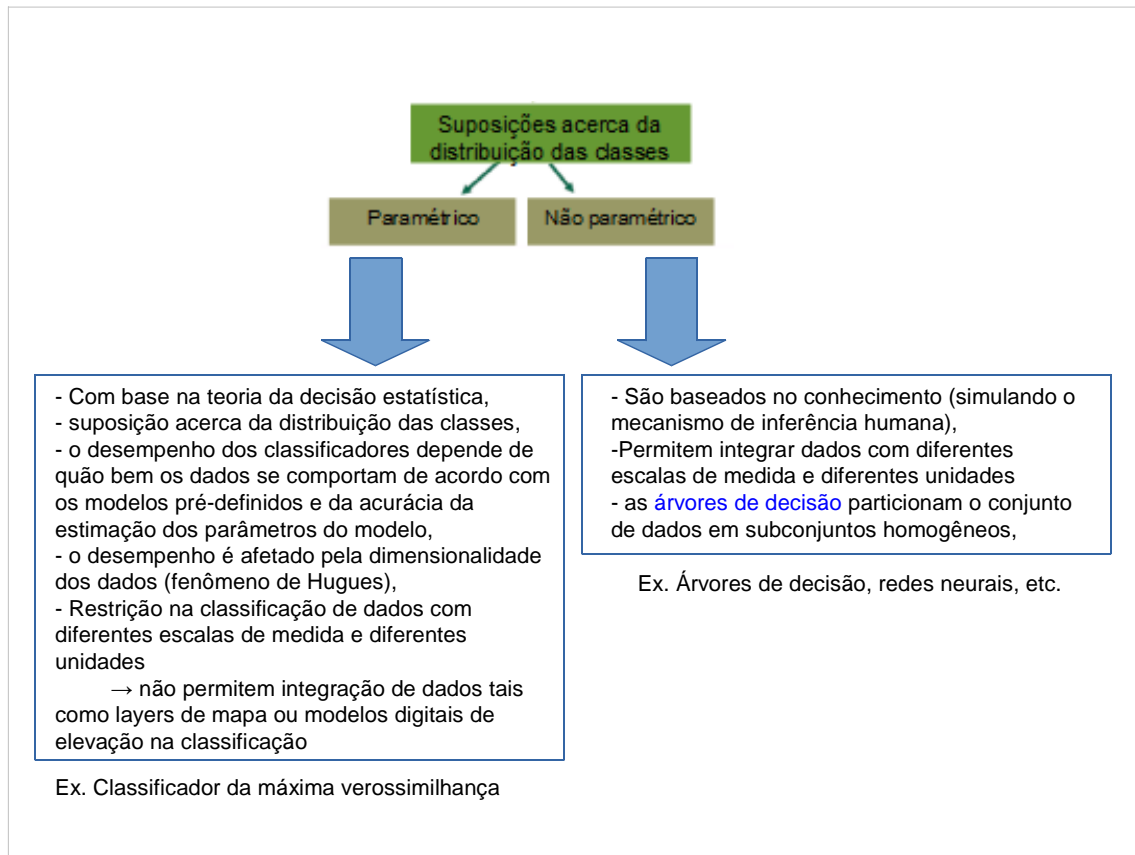
→ máxima verossimilhança

Métodos não paramétricos não adotam as suposições anteriores.

Exemplos:

→ árvores de decisão

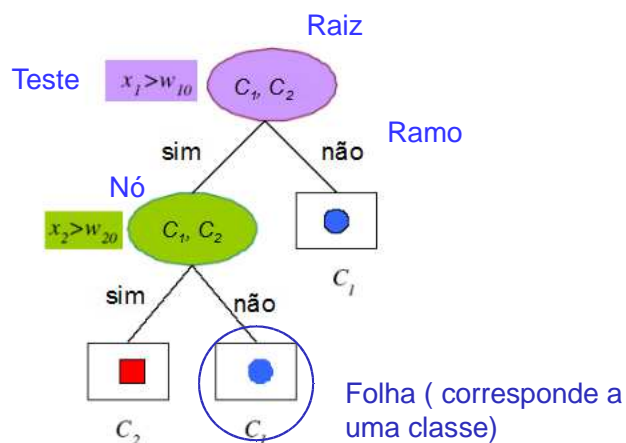
→ redes neurais



Árvore de decisão

A árvore consiste de:

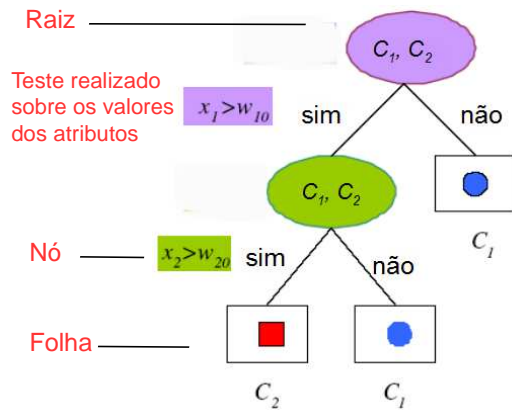
- Raiz
- Ramos
- Nós
- Folhas



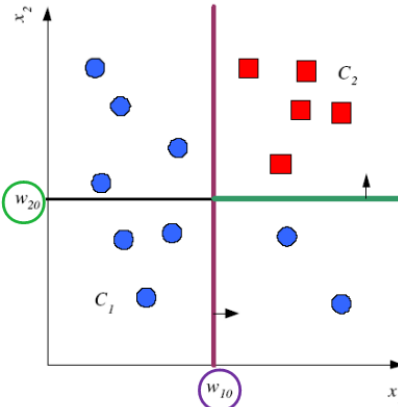
Na *raiz* e em cada *nó* é realizado o teste de **algum atributo**, e cada ramo descendente daquele nó corresponde a um dos possíveis valores para este atributo.

As **árvores de decisão** particionam o conjunto de dados em subconjuntos homogêneos.

-Interpretação geométrica das árvores de decisão:



Árvore de decisão

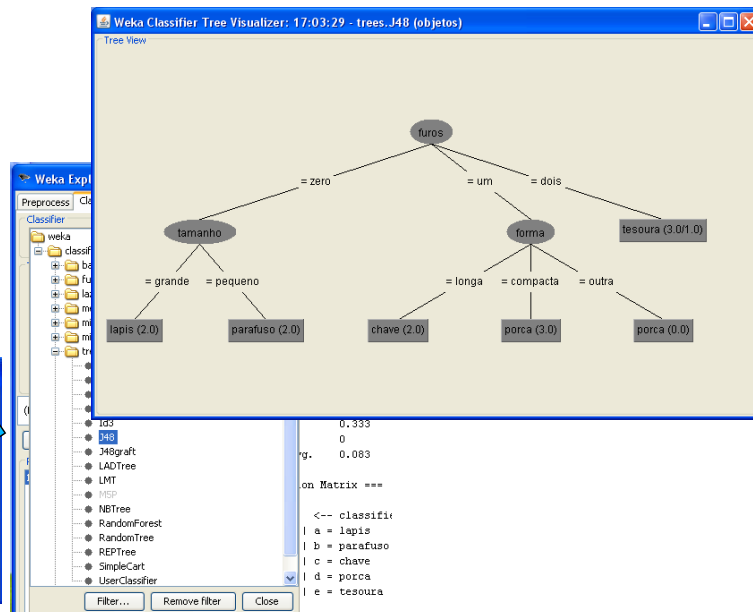



Espaço de atributos bidimensional com duas classes

```
% ARFF file objetos
@relation objetos
@attribute tamanho { grande, pequeno}
@attribute forma {longa, compacta, outra}
@attribute furos {zero, um, dois}
@attribute objeto { lapis, parafuso, chave, porca, tesoura }
```

```
@data
% instancias
grande, longa, zero, lapis
grande, longa, zero, lapis
pequeno, longa, zero, parafuso
pequeno, compacta, zero, parafuso
grande, longa, um, chave
pequeno, compacta, um, porca
pequeno, longa, um, chave
pequeno, compacta, um, porca
pequeno, compacta, um, porca
grande, longa, dois, tesoura
grande, outra, dois, tesoura
pequeno, outra, dois, chave
```

Árvore de decisão inferida com o WEKA utilizando o algoritmo C4.5 (J48):



Base de Conhecimento:

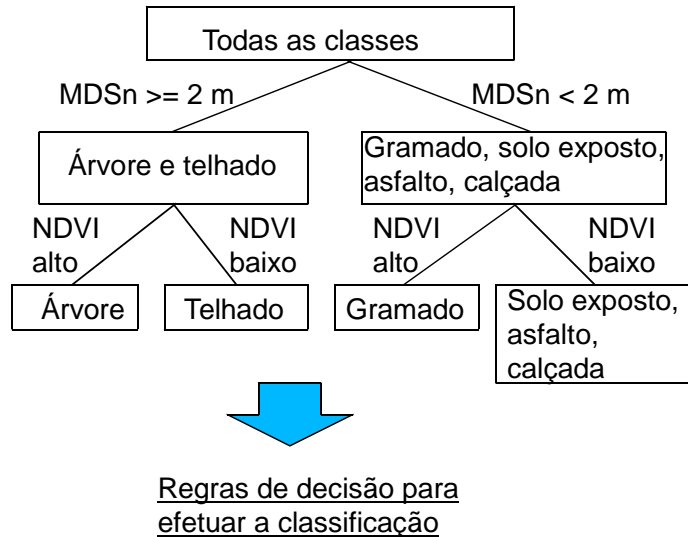
As árvores tem NDVI alto e elevação superior a 1,5 m.

Os telhados tem NDVI baixo e elevação superior a 2 m.

O gramado tem NDVI alto e elevação próxima a zero no MDSn.

O solo exposto, asfalto e calçada tem NDVI baixo e elevação próxima a zero.

Árvore de decisão :



Para implementação no Matlab, as regras terão o seguinte aspecto:

```
if MDSn(i,j) <2 & NDVI(i,j) >= x
    Classe(i,j) = 1; % gramado

elseif MDSn(i,j) >=2 & NDVI(i,j) >= x
    Classe(i,j) = 2; % arvore

elseif MDSn(i,j) <2 & NDVI(i,j) < x
    Classe(i,j) = 3; % solo, asfalto



elseif MDSn(i,j) >=2 & NDVI(i,j) < x
    Classe(i,j) = 4; % telhado

end
```

Exercício:

Considere os seguintes dados:

- NDVI, índice normalizado de diferença de vegetação, gerado a partir de uma imagem Quickbird ortorretificada,
- MDSn, modelo digital de superfície normalizado.



ocusão

MDSn : resolução espacial de 0.7m ; 8 bits.

NDVI : resolução espacial de 0.7m ; 8 bits, com valor 0 para área de oclusão.

→ Testes indicaram que valores de NDVI correspondem à vegetação.

```
NDVI=imread('ndvi.tif');
MDS=imread('MDSn_metros.tif');
[m,n]=size(MDS)
Classe = zeros(m,n);

% 1 = gramado
% 2 = arvore
% 3 = solo, asfalto
% 4 = telhado

for i = 1: m
for j = 1:n
    if MDS(i,j) <2 & NDVI(i,j) > 90
        Classe(i,j) = 1;
    elseif MDS(i,j) >2 & NDVI(i,j) > 90
        Classe(i,j) = 2;
    elseif MDS(i,j) <2 & NDVI(i,j) < 90
        Classe(i,j) = 3;
    elseif MDS(i,j) >2 & NDVI(i,j) < 90
        Classe(i,j) = 4;
    end
end

result = uint8(Classe);
imwrite(Classe,'classes.tif', 'compress', 'none')
```